

Explication détaillée du projet

Pump Price Prediction - datasets, transformations, features et modèles

Objectif du projet

Le projet cherche à prédire si le prix de l'essence régulière à la pompe aux États-Unis va augmenter la semaine suivante. C'est donc un problème de classification binaire : 1 signifie que le prix augmente la semaine suivante, 0 signifie qu'il baisse ou ne monte pas.

L'intérêt business est de tester si des signaux liés au transport maritime de pétrole peuvent compléter les signaux classiques du marché énergétique, en particulier le prix du Brent. L'idée n'est pas de remplacer un modèle professionnel de prix de l'énergie, mais de construire une preuve de concept claire : peut-on combiner Brent, prix à la pompe et trafic tanker autour de détroits stratégiques pour obtenir un signal exploitable à court terme ?

Dataset 1 - PortWatch

Le premier dataset utilisé est PortWatch, une source de données qui fournit des observations quotidiennes du trafic maritime autour de grands chokepoints mondiaux. Dans le projet, le fichier brut est `data/raw/portwatch_daily_chokepoints.csv`.

Ce dataset contient notamment la date, le nom du chokepoint, le nombre de navires observés, le nombre de tankers, ainsi que des variables de capacité. Pour ce projet, on utilise surtout le nombre de tankers, car les tankers sont directement liés aux flux d'énergie, de pétrole, de gaz ou de produits pétroliers.

Les détroits retenus sont le Strait of Hormuz, Bab el-Mandeb Strait, Suez Canal et Malacca Strait. Ils sont choisis car ils sont stratégiques pour les routes énergétiques mondiales. Ormuz est particulièrement important pour les flux venant du Golfe persique. Bab el-Mandeb et Suez sont liés aux routes mer Rouge / Méditerranée. Malacca est un passage majeur vers l'Asie.

Dataset 2 - Prix de l'essence FRED

Le deuxième dataset est la série FRED GASREGW. Elle représente le prix hebdomadaire de l'essence régulière aux États-Unis, en dollars par gallon.

C'est la variable centrale du projet, car c'est à partir de cette série qu'on construit la cible. On ne prédit pas directement le niveau exact du prix, mais la direction de son mouvement : est-ce que le prix sera plus haut la semaine suivante ?

La fréquence de GASREGW est hebdomadaire. C'est pour cette raison que les données PortWatch, initialement quotidiennes, sont agrégées à la semaine.

Dataset 3 - Brent FRED

Le troisième dataset est la série FRED DCOILBRENTU, qui correspond au prix du Brent brut. Le Brent est un benchmark majeur du marché pétrolier mondial. Il est important car les prix à la pompe dépendent fortement du prix du pétrole brut, même si la relation n'est pas parfaite.

Le Brent est disponible à fréquence quotidienne. Dans le projet, il est transformé à fréquence hebdomadaire en prenant la dernière valeur disponible de la semaine. Cela donne une série compatible avec la fréquence du prix à la pompe.

Données optionnelles

Le script de préparation essaie aussi d'intégrer certaines variables macroéconomiques depuis FRED quand elles sont disponibles. Dans le dataset final actuel, on retrouve notamment `usd_index` et `usd_return_4w`. L'idée est de capter un effet macro plus large : le dollar peut influencer le marché pétrolier car le pétrole est coté en dollars.

Ces variables sont optionnelles : si une série n'est pas disponible au moment de l'exécution, le pipeline continue sans bloquer. C'est utile pour rendre le projet plus robuste.

Transformation 1 - Harmonisation temporelle

La première grande transformation consiste à mettre toutes les données à la même fréquence temporelle. PortWatch est quotidien, le Brent est quotidien, et le prix à la pompe est hebdomadaire.

PortWatch est agrégé avec un resampling hebdomadaire le lundi. Pour chaque détroit, on calcule la moyenne hebdomadaire du nombre de tankers et de la capacité tanker. Le Brent est aussi ramené à la semaine, avec la dernière valeur disponible. Le prix à la pompe est déjà hebdomadaire.

Cette harmonisation est essentielle : on ne peut pas entraîner un modèle proprement si

les variables ne correspondent pas aux mêmes dates.

Transformation 2 - Fusion des sources

Après l'agrégation temporelle, les différentes sources sont fusionnées par date. On obtient une table hebdomadaire unique où chaque ligne correspond à une semaine.

Chaque ligne contient donc le prix à la pompe, le prix du Brent, le trafic tanker des détroits, les variables dérivées, et la cible à prédire. Le dataset final est sauvegardé dans `data/processed/pump_price_dataset.csv`.

Dans la version actuelle, le dataset final contient 377 observations hebdomadaires et 57 colonnes, couvrant la période du 4 février 2019 au 20 avril 2026. La cible est presque équilibrée : environ 50,1% des semaines correspondent à une hausse du prix la semaine suivante.

Transformation 3 - Features maritimes

Pour chaque détroit, plusieurs variables sont créées à partir du trafic tanker.

La première variable est le trafic tanker hebdomadaire brut, par exemple `strait_of_hormuz_n_tanker`. Ensuite, on crée des moyennes mobiles sur 4 semaines et 12 semaines. La moyenne mobile 4 semaines donne une tendance récente, tandis que la moyenne mobile 12 semaines donne une tendance plus longue.

On calcule aussi un écart-type mobile sur 4 semaines pour mesurer la volatilité récente du trafic. Les ratios sur 12 semaines comparent le trafic actuel à sa tendance longue. Par exemple, un ratio inférieur à 1 peut signaler un trafic plus faible que d'habitude.

Enfin, on ajoute des variables retardées, ou lags, à 1, 2 et 4 semaines. Ces variables permettent au modèle d'utiliser l'information passée plutôt que seulement la valeur actuelle.

Transformation 4 - Indicateur de stress maritime

Le projet construit un indicateur `maritime_stress`. Il est basé sur les ratios d'anomalie du trafic tanker autour des détroits sélectionnés.

L'intuition est simple : si le trafic actuel est inférieur à sa tendance, cela peut signaler une perturbation ou une tension sur certaines routes. Le stress maritime agrège ces signaux sur plusieurs chokepoints.

Cet indicateur ne prétend pas mesurer parfaitement le risque géopolitique. Il sert plutôt de proxy quantitatif pour représenter une situation inhabituelle dans le trafic énergétique maritime.

Transformation 5 - Features Brent et prix pompe

Le Brent est transformé en plusieurs variables. On calcule `brent_return_1w`, qui est la variation hebdomadaire du Brent, et `brent_return_4w`, qui capte une tendance sur quatre semaines. On calcule aussi `brent_vol_4w`, qui mesure la volatilité récente du Brent.

Des lags de `brent_return_1w` sont aussi ajoutés, afin que le modèle puisse tenir compte de l'effet retardé d'une variation du pétrole sur le prix à la pompe.

Pour le prix à la pompe, on crée `pump_return_1w` et `pump_return_4w`. Ces variables capturent le momentum du prix à la pompe. Les lags de `pump_return_1w` permettent au modèle d'utiliser les mouvements récents comme signal prédictif.

Transformation 6 - Saisonnalité

Le prix de l'essence dépend aussi de la saison. Par exemple, la demande peut augmenter pendant la driving season aux États-Unis, souvent autour des mois de mai à août.

Le projet ajoute donc plusieurs variables temporelles : `month`, `week_of_year`, `is_driving_season` et `is_winter`. Ces variables aident le modèle à capter des régularités saisonnières simples.

Variable cible

La cible s'appelle `target_price_up_1w`. Elle est construite à partir de `target_return_1w`, qui correspond à la variation du prix à la pompe la semaine suivante.

Si `target_return_1w` est positif, alors `target_price_up_1w` vaut 1. Sinon, elle vaut 0.

Ce choix transforme le problème en classification binaire. C'est plus simple et plus robuste que de prédire directement le prix exact, surtout avec un dataset relativement petit.

Features utilisées dans le modèle final

Les features finales utilisées par les modèles sont regroupées en quatre familles.

Première famille : les variables maritimes. Elles incluent le trafic tanker pour Ormuz,

Bab el-Mandeb, Suez et Malacca, les moyennes mobiles, les ratios d'anomalie et certains lags.

Deuxième famille : les variables Brent. Elles incluent `brent_price`, `brent_return_1w`, `brent_return_4w`, `brent_vol_4w` et les lags de `brent_return_1w`.

Troisième famille : les variables liées au prix à la pompe. Elles incluent `pump_price`, `pump_return_1w`, `pump_return_4w` et les lags de `pump_return_1w`.

Quatrième famille : les variables calendaires. Elles incluent `month`, `week_of_year`, `is_driving_season` et `is_winter`.

Le modèle utilise donc à la fois des signaux énergétiques classiques, des signaux maritimes et des signaux saisonniers.

Modèles utilisés

Trois modèles sont utilisés : Logistic Regression, Random Forest et Gradient Boosting.

La régression logistique sert de modèle simple et interprétable. Elle est adaptée lorsqu'on a peu de données et lorsqu'une grande partie du signal peut être approximée par des relations relativement linéaires.

Random Forest est un modèle d'ensemble d'arbres. Il peut capturer des relations non linéaires, mais il peut aussi sur-apprendre lorsque le dataset est petit.

Gradient Boosting est aussi un modèle d'arbres, mais construit de manière séquentielle. Il est souvent performant, mais il peut également être sensible au bruit et au faible volume de données.

Pourquoi la régression logistique est la meilleure ici

La régression logistique ressort comme le meilleur modèle sur les métriques principales du test set. Elle obtient environ 65,8% d'accuracy, 0,618 de F1 score et 0,728 de ROC AUC.

Ce résultat est cohérent avec la nature du dataset. Le dataset final contient seulement 377 semaines. Après le split chronologique, le test set contient une partie encore plus petite. Dans ce contexte, un modèle simple peut mieux généraliser qu'un modèle très flexible.

Random Forest et Gradient Boosting peuvent apprendre des interactions plus complexes,

mais avec peu de données, ils risquent davantage de capter du bruit historique plutôt qu'un signal stable. La régression logistique impose une structure plus simple, ce qui limite l'overfitting.

Un autre point important est que le prix à la pompe dépend fortement de variables directionnelles comme le Brent et le momentum récent du prix. Ces relations peuvent être captées correctement par un modèle linéaire. La complexité supplémentaire des modèles d'arbres n'apporte donc pas forcément un gain sur les données de test.

Enfin, la régression logistique a la meilleure précision parmi les modèles : environ 0,724. Cela signifie que lorsqu'elle prédit une hausse, elle se trompe moins souvent que les autres modèles. Dans un usage business, cela peut être intéressant si l'objectif est d'identifier des signaux de hausse relativement fiables.

Lecture des résultats

Les scores doivent être interprétés avec prudence. Une accuracy autour de 66% peut sembler modeste, mais pour une prédiction hebdomadaire de direction de prix, c'est déjà au-dessus du hasard.

Le ROC AUC autour de 0,73 indique que le modèle sait relativement bien classer les semaines plus risquées en hausse par rapport aux semaines moins risquées. Ce n'est pas parfait, mais cela montre qu'il existe un signal exploitable.

Le fait que la cible soit presque équilibrée, avec environ 50,1% de semaines en hausse, rend l'accuracy plus lisible : un modèle naïf qui prédit toujours la classe majoritaire serait proche de 50%, alors que la régression logistique est autour de 66%.

Variables les plus importantes

Pour la régression logistique, les variables les plus importantes sont principalement `brent_return_1w`, `pump_return_1w` et `brent_return_4w`. Cela confirme que le Brent et le momentum récent du prix à la pompe sont les signaux principaux.

On retrouve aussi des variables calendaires comme `week_of_year` et `month`, ce qui indique une composante saisonnière. Certaines variables maritimes apparaissent également, par exemple `malacca_strait_n_tanker_ma4`, `strait_of_hormuz_n_tanker_lag1` ou `suez_canal_n_tanker`. Elles semblent jouer un rôle complémentaire.

L'interprétation importante est donc la suivante : le trafic maritime ne remplace pas le

Brent, mais il peut enrichir légèrement le signal en représentant des tensions ou des changements dans les routes énergétiques.

Limites

La première limite est la taille du dataset. Avec 377 observations hebdomadaires, on ne peut pas entraîner des modèles très complexes de manière totalement robuste.

La deuxième limite est que le prix à la pompe dépend de nombreux facteurs absents du dataset : taxes, marges de raffinage, stocks régionaux, demande locale, politiques publiques, météo, capacités de raffinage et chocs géopolitiques.

La troisième limite est que le trafic tanker n'est pas une causalité directe. Une variation du trafic autour d'un détroit peut être liée à beaucoup de phénomènes différents et ne signifie pas automatiquement une hausse du prix à la pompe.

La quatrième limite est le choix de la cible. Le modèle prédit seulement la direction du prix à une semaine, pas le niveau exact du prix. C'est une bonne approche pour une preuve de concept, mais elle ne suffit pas pour prévoir précisément le prix en dollars.

Enfin, le modèle reste sensible à la période étudiée. Les relations entre Brent, trafic maritime et prix à la pompe peuvent changer selon les régimes économiques, les crises ou les politiques énergétiques.

Améliorations possibles

Pour améliorer le projet, on pourrait ajouter plus de variables énergétiques, comme les stocks d'essence, les marges de raffinage, les prix régionaux, la demande américaine ou les capacités de raffinage.

On pourrait aussi tester plusieurs horizons : une semaine, deux semaines, quatre semaines. Cela permettrait de savoir à quel horizon les signaux maritimes sont les plus utiles.

Une autre amélioration serait d'ajouter des événements géopolitiques codés manuellement, par exemple des attaques en mer Rouge, des tensions autour d'Ormuz ou des annonces de l'OPEP.

Enfin, on pourrait passer d'une classification binaire à une prédiction de rendement ou de niveau de prix, mais cela demanderait plus de données et une validation plus stricte.

Conclusion

Ce projet montre qu'il est possible de construire une preuve de concept reliant prix à la pompe, Brent et trafic maritime de tankers.

Le résultat principal est que le Brent et le momentum du prix à la pompe restent les signaux dominants. Les variables maritimes apportent un signal secondaire, utile pour représenter le stress potentiel sur les routes énergétiques.

La régression logistique ressort comme le meilleur modèle car elle généralise mieux sur un dataset limité. Elle est simple, interprétable et moins sujette à l'overfitting que des modèles d'arbres plus complexes.

Le projet est donc pertinent comme outil pédagogique et comme première base d'analyse, mais il doit être présenté comme une preuve de concept, pas comme un modèle professionnel de prévision des prix énergétiques.