

Datasets utilisés

Objectif : prédire la hausse du prix de l'essence US la semaine suivante

PortWatch - trafic maritime

Données journalières de trafic autour des chokepoints. Utilisées pour extraire le trafic de tankers sur Ormuz, Bab el-Mandeb, Suez et Malacca.

FRED GASREGW - prix à la pompe

Prix hebdomadaire de l'essence régulière aux États-Unis. C'est la série utilisée pour construire la variable cible.

FRED DCOILBRENTU - Brent

Prix du Brent brut, indicateur central du marché pétrolier mondial.

Dataset final

377 observations hebdomadaires, de février 2019 à avril 2026, avec une cible presque équilibrée : environ 50 % de semaines en hausse.

Features créées

Transformer des séries brutes en signaux exploitables par les modèles

Features Brent

Prix du Brent, variation 1 semaine, variation 4 semaines, volatilité 4 semaines, lags des variations.

Features prix à la pompe

Prix courant, momentum 1 semaine, momentum 4 semaines, lags du momentum.

Features maritimes

Trafic tanker hebdomadaire, moyennes mobiles 4 et 12 semaines, ratios d'anomalie, lags par détroit.

Stress maritime

Indicateur agrégé basé sur les anomalies de trafic tanker autour des détroits stratégiques.

Saisonnalité

Mois, semaine de l'année, driving season, hiver.

3 modèles testés

Même objectif : classifier hausse ou non-hausse à horizon 1 semaine

Logistic Regression

Modèle simple, interprétable et robuste avec peu de données. Meilleur modèle actuel : accuracy $\approx 66\%$, ROC AUC $\approx 0,73$.

Random Forest

Ensemble d'arbres capable de capter des relations non linéaires. Moins performant ici, probablement car le dataset est petit.

Gradient Boosting

Modèle d'arbres boostés, performant sur relations complexes. Résultat proche de la régression logistique, ROC AUC $\approx 0,73$.

Pourquoi la Logistic Regression ressort mieux ?

Le dataset contient seulement 377 semaines. Un modèle plus simple généralise mieux et limite l'overfitting.

Limites et améliorations

Le projet est une preuve de concept, pas un modèle énergétique professionnel

Taille du dataset

Seulement quelques centaines d'observations hebdomadaires, donc les modèles complexes peuvent sur-apprendre.

Variables manquantes

Taxes, marges de raffinage, stocks régionaux, météo, demande locale, décisions OPEP, événements géopolitiques.

Pas de causalité directe

Le trafic tanker est un signal de stress potentiel, mais ne prouve pas une causalité sur le prix à la pompe.

Cible simplifiée

Le modèle prédit seulement la direction à une semaine, pas le prix exact en dollars.

Pistes

Ajouter plus de variables énergétiques, tester plusieurs horizons, intégrer des événements géopolitiques, utiliser des modèles temporels.