

Présentation orale - Projet Pump Price Prediction

Présentation du projet

Bonjour, je vais vous présenter mon projet de machine learning. L'objectif est de prédire si le prix de l'essence à la pompe aux États-Unis va augmenter ou diminuer la semaine suivante.

L'idée business est la suivante : le prix à la pompe dépend fortement du prix du pétrole, notamment du Brent, mais il peut aussi être influencé par des tensions dans les chaînes d'approvisionnement énergétiques. Comme une grande partie du pétrole circule par voie maritime, j'ai voulu tester si le trafic de tankers autour de grands détroits stratégiques pouvait apporter un signal supplémentaire.

Structure GitHub

Je vais d'abord montrer rapidement mon dépôt GitHub. On retrouve la structure demandée pour le projet. Dans `data/raw`, j'ai les données brutes PortWatch sur le trafic maritime. Dans `data/processed`, j'ai le dataset final utilisé pour entraîner les modèles. Dans `scripts`, il y a les scripts pour préparer les données, entraîner les modèles et lancer l'évaluation. Dans `src`, on retrouve les fichiers imposés par le template du professeur : `data.py`, `metrics.py`, `config.py` et `app.py`. Dans `models`, les modèles entraînés sont sauvegardés. Dans `results`, on retrouve les métriques finales. Et dans `plots`, les graphiques utilisés dans l'analyse et dans l'application Streamlit.

Données utilisées

Concernant les données, j'utilise trois grands types de sources. Premièrement, j'utilise les données PortWatch, qui donnent le trafic maritime journalier autour de différents chokepoints. Je les agrège à la semaine, car le prix de l'essence à la pompe est aussi disponible à fréquence hebdomadaire. Je me concentre surtout sur le trafic de tankers autour de détroits stratégiques comme le détroit d'Ormuz, Bab el-Mandeb, le canal de Suez et le détroit de Malacca.

Deuxièmement, j'utilise les données FRED sur le prix de l'essence régulier aux États-Unis, avec la série GASREGW. C'est la variable que je cherche à prédire. Troisièmement, j'utilise le prix du Brent, également récupéré via FRED, avec la série DCOILBRETEU. Le Brent est important car il représente un indicateur central du marché pétrolier mondial.

À partir de ces données, je construis plusieurs variables explicatives : les rendements hebdomadaires du Brent, les variations du prix à la pompe, des moyennes mobiles du trafic tanker, des ratios d'anomalie sur le trafic maritime, un indicateur de stress maritime, ainsi que des variables de saisonnalité comme le mois, la semaine de l'année ou la période estivale.

La variable cible est volontairement simple : est-ce que le prix de l'essence sera plus élevé la semaine prochaine ? C'est donc un problème de classification binaire, avec deux classes : hausse ou baisse.

Modèles

Pour les modèles, j'ai utilisé trois approches classiques : une régression logistique, un Random Forest et un Gradient Boosting. Je n'ai pas cherché à multiplier les modèles. L'objectif était plutôt de garder des modèles simples et comparables, puis d'améliorer la qualité du projet avec un meilleur feature engineering, une séparation chronologique entre train et test, et une recherche d'hyperparamètres.

Le split chronologique est important. Comme on travaille sur des données temporelles, il ne faut pas mélanger le futur avec le passé. Le modèle est donc entraîné sur les anciennes observations et testé sur les semaines les plus récentes. Cela donne une évaluation plus réaliste.

Application Streamlit

Maintenant, dans l'application Streamlit, on peut voir une synthèse du projet. Dans l'onglet overview, on retrouve la logique business et les graphiques principaux. Le premier graphique compare l'évolution du prix à la pompe et du Brent. On voit que les deux séries sont très liées, ce qui est cohérent économiquement. Le deuxième graphique montre le trafic de tankers autour des détroits stratégiques. L'idée n'est pas de dire que le trafic maritime explique tout, mais de vérifier s'il peut apporter un signal complémentaire au prix du Brent.

Résultats

Dans l'onglet modèles, on retrouve la comparaison des performances. Le meilleur modèle actuel est la régression logistique, avec une accuracy d'environ 66 % et un ROC AUC autour de 0,73. Pour une prédiction hebdomadaire de hausse ou baisse du prix à la pompe, ce résultat est plutôt correct. On est au-dessus du hasard, mais on reste sur un

phénomène difficile à prédire.

Le Gradient Boosting obtient aussi un ROC AUC proche de 0,73, ce qui montre que les modèles captent un signal réel, mais pas extrêmement fort. C'est cohérent avec le sujet : les prix de l'énergie dépendent de beaucoup de facteurs et les marchés réagissent rapidement.

On peut aussi regarder l'importance des variables. Les variables liées au Brent et au momentum récent du prix à la pompe sont centrales. Les variables de trafic maritime jouent plutôt un rôle secondaire, comme un signal de stress ou d'anomalie. Cela veut dire que le trafic tanker n'est pas le facteur principal, mais il peut enrichir l'information disponible.

Dans l'onglet simulateur, on peut modifier certains paramètres, par exemple une variation du Brent ou un niveau de stress maritime, et comparer la prédiction des différents modèles. Cela permet de rendre le projet plus concret et plus interactif.

Conclusion

La conclusion principale est que le Brent reste le facteur dominant pour anticiper les mouvements du prix de l'essence à court terme. Cependant, les données maritimes peuvent enrichir le modèle, surtout comme indicateur de risque ou de tension dans l'approvisionnement énergétique.

Le projet montre donc qu'on peut combiner des données énergétiques classiques avec des données de trafic maritime pour construire un outil de prévision court terme. Ce n'est pas un modèle parfait, mais c'est une preuve de concept intéressante.

Limites

Il y a toutefois plusieurs limites importantes. Premièrement, le dataset reste relativement petit, car on travaille à fréquence hebdomadaire. On a donc seulement quelques centaines d'observations. Deuxièmement, le prix à la pompe dépend de beaucoup d'autres facteurs : les taxes, les marges de raffinage, les stocks, la demande locale, la politique énergétique ou encore les événements géopolitiques. Le modèle ne capture pas tout.

Troisièmement, le trafic tanker n'est pas une causalité directe. Une baisse ou une hausse du trafic dans un détroit ne signifie pas automatiquement que le prix à la pompe

va bouger. Enfin, le projet prédit seulement une direction à une semaine, pas le niveau exact du prix.

Pour aller plus loin, on pourrait ajouter plus de variables énergétiques, tester plusieurs horizons de prédiction, intégrer des événements géopolitiques, ou passer vers une vraie modélisation de séries temporelles.

En résumé, ce projet ne remplace pas un modèle énergétique professionnel, mais il montre qu'il existe un signal exploitable en combinant Brent, prix à la pompe et données maritimes. L'intérêt principal est d'avoir un outil clair, interactif et interprétable pour analyser un problème économique concret.